

Fundamentos de Dados

Apostila da trilha coleta, limpeza e leitura crítica de dados

por Beatriz Lima

Material de estudo da plataforma MentorHub mentorhub.demonstrando.com.br

1. Dado não é informação

Um número solto não conta nada. "47% de churn" não conta nada até você saber de QUE período, de QUAL segmento e em COMPARAÇÃO a quê.

O trabalho com dados começa exatamente aí: transformar número em contexto, contexto em informação, informação em decisão.

As três perguntas de todo dado

1. ****Origem****: quem mediu, como, com qual instrumento?
2. ****Escopo****: qual população, qual janela de tempo?
3. ****Comparação****: acima ou abaixo de quê?

Pule qualquer uma delas e você estará apresentando opinião com cara de estatística.

2. Coleta: o lixo entra pela porta da frente

80% do tempo de qualquer trabalho com dados vai em **limpeza** e a maior parte da sujeira nasce na coleta.

Regras de sobrevivência

- **Nomeie antes de coletar**: evento "signup_click" hoje e "cadastro_finalizado" amanhã quebra qualquer análise.
- **Versione o dicionário de dados**: cada campo tem dono, tipo e descrição.
- **Não corrija na mão**: correção manual não escala e não é auditável. Corrija na origem.

O teste do repaint

Se você reprocessasse toda a coleta do zero, chegaria aos mesmos números? Se a resposta for "não sei", sua coleta não é confiável e toda análise em cima dela é um castelo de areia.

3. Limpeza: um checklist honesto

Antes de qualquer análise

- Duplicatas exatas e quase-exatas (mesmo usuário, e-mail com maiúscula/minúscula).
- Nulos: estão vazios porque não existe, porque não souberam ou porque deu erro?
- Outliers: primeiro investigue, depois decida. Excluir sem entender é censurar o dado.
- Tipos: data como texto é o clássico e o mais caro de descobrir tarde.

Documente o que você fez

Cada transformação vai no log da análise. A pergunta "como você chegou nesse número?" precisa de resposta em 30 segundos não em uma tarde.

4. Leitura crítica: os erros que mais enganam

Média sem distribuição

"Tempo médio de resposta: 3min" com metade respondendo em 10s e metade em 6min? A média esconde dois produtos diferentes.

Correlação vira causalidade

Vendas de sorvete e afogamentos sobem juntos. Não é o sorvete.

Sobrevivência

Você ouve o sucesso dos que usaram a ferramenta nunca dos que abandonaram. O chamado "viés do sobrevivente" é o mais comum em cases de marketing.

P-hacking honesto

Se você testar 20 hipóteses, uma vai "dar significativa" por acaso. Corrija o p-valor ou declare todas as hipóteses ANTES de olhar os dados.

5. Do número à decisão

Uma análise só vale quando termina em uma decisão melhor. O formato que uso para comunicar:

O parágrafo de decisão

1. **Pergunta**: o que estávamos tentando responder?
2. **Evidência**: o número, com escopo e comparação.
3. **Limitação**: o que este número NÃO responde.
4. **Recomendação**: o que fazer (e o que NÃO fazer ainda).

Quatro linhas. Se a sua análise precisa de vinte slides para explicar, provavelmente ela ainda não sabe qual é a pergunta.

Próximos passos

Aplique o checklist da apostila no último relatório que você recebeu. Quantas das três perguntas (origem, escopo, comparação) ele responde? O gap é o seu plano de estudo e o assunto da próxima mentoria.